

# Women's Clothing E-Commerce dataset revolving around the reviews

OPRACOWALI: AGNIESZKA DĄBROWSKA-MAŁYSZKO, WITOLD ŁAŃCUCKI, PAULINA SOKAL, IRENEUSZ TUR

# Informacje wstępne:

- W zbiorze danych mam 23 486 wierszy i 10 zmiennych dla każdego z nich. Każdy z nich to jedna ocena klienta:
- Clothing ID: Integer
- Age: Integer
- ▶ Title: String
- Review Text: String
- Rating: Integer w zakresie od 1 do 5, gdzie 1 to najniższa ocena, a 5 najlepsza
- Recommended IND: Binary variable, gdzie 1 = ,polecam', a 0 = ,nie polecam'
- Positive Feedback Count: Integer
- Division Name: String
- Department Name: String
- ▶ Class Name: String

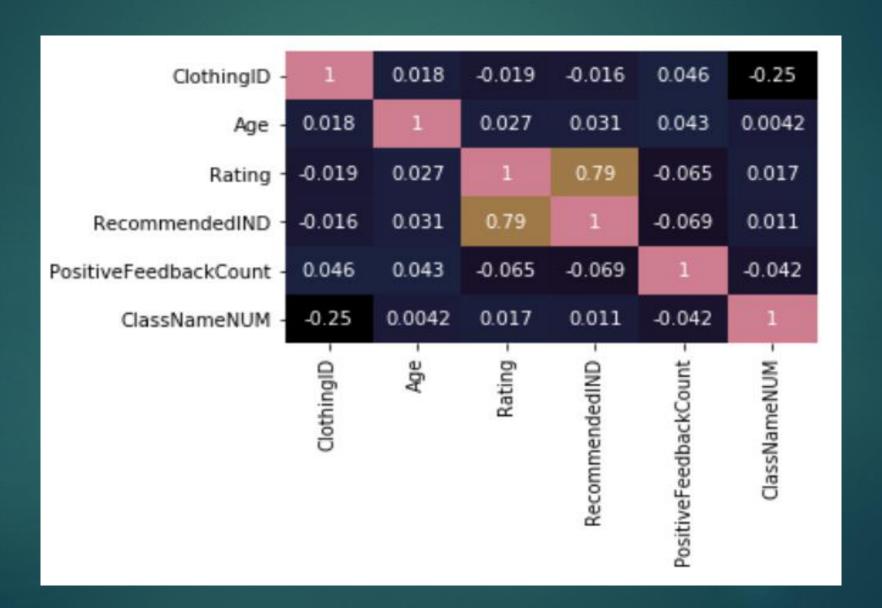
### PLAN:

- ► ANALIZA DANYCH LICZBOWYCH
- ► ANALIZA KOMENTARZY
- ANALIZA CZYNNIKOWA

## PODSTAWOWE DANE STATYSTYCZNE

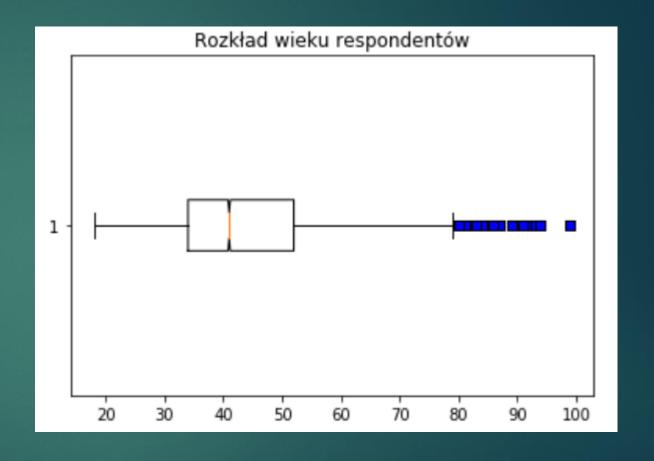
		Age	Rating	RecommendedIND	PositiveFeedbackCount
(	count	23486.000000	23486.000000	23486.000000	23486.000000
	mean	43.198544	4.196032	0.822362	2.535936
	std	12.279544	1.110031	0.382216	5.702202
	min	18.000000	1.000000	0.000000	0.000000
	25%	34.000000	4.000000	1.000000	0.000000
	50%	41.000000	5.000000	1.000000	1.000000
	<b>75</b> %	52.000000	5.000000	1.000000	3.000000
	max	99.000000	5.000000	1.000000	122.000000

#### KORELACJA

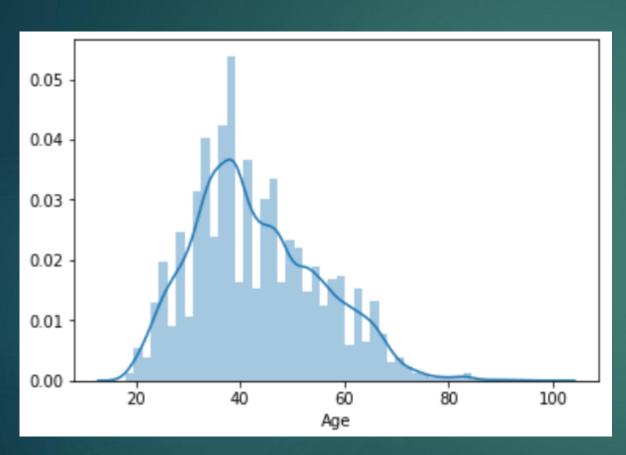


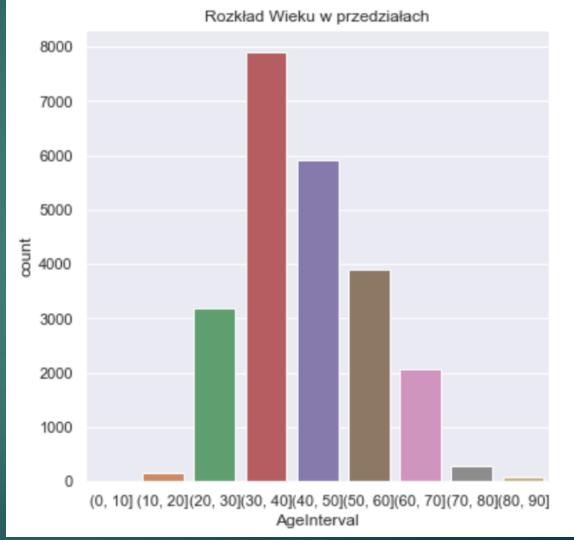
# Kilka słów o wieku

	AgeInterval	Rating	Percentage
0	(0, 10]	0	0.000000
1	(10, 20]	152	0.647553
2	(20, 30]	3186	13.573041
3	(30, 40]	7912	33.706812
4	(40, 50]	5908	25.169344
5	(50, 60]	3891	16.576492
6	(60, 70]	2057	8.763260
7	(70, 80]	281	1.197120
8	(80, 90]	86	0.366378

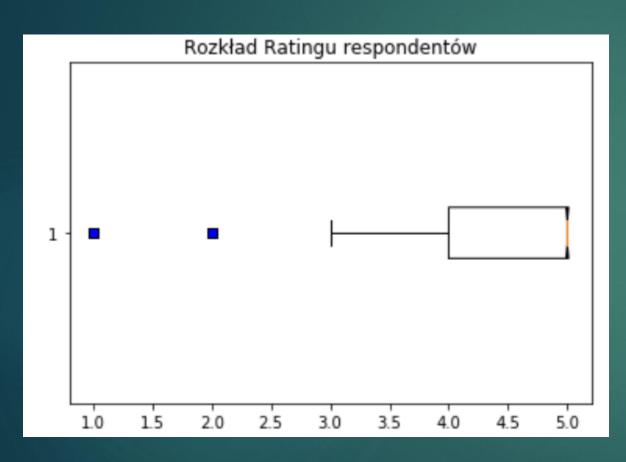


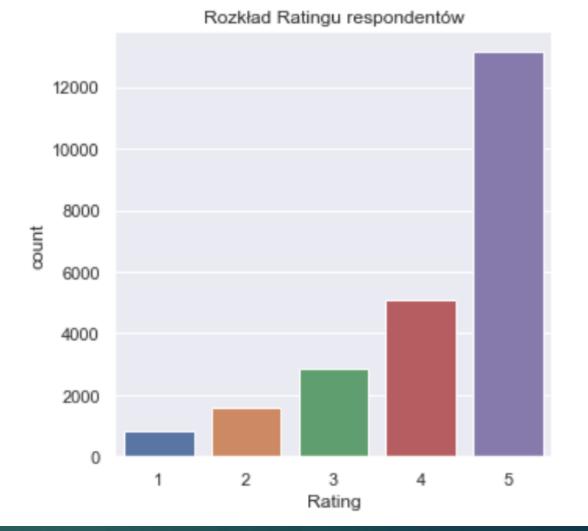
## Kilka słów o wieku





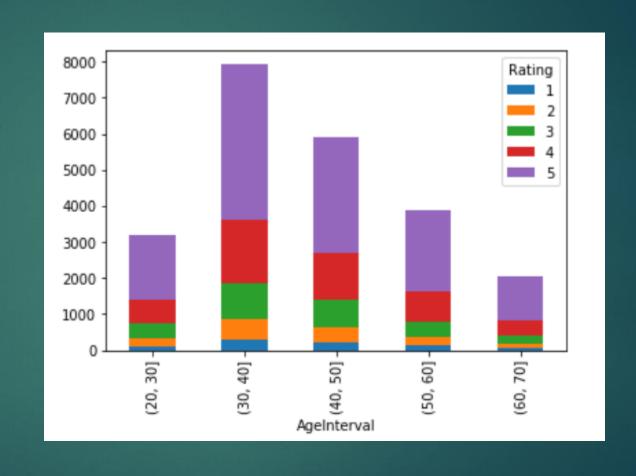
# Rating jako miara zadowolenia



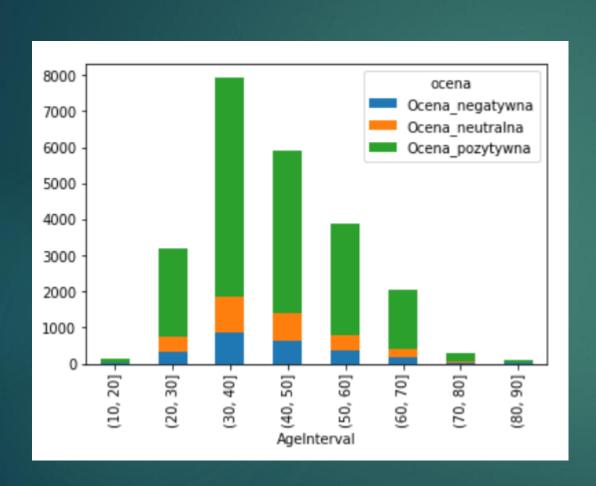


# Rating a wiek

AgeInterval	Rating	
(20, 30]	1	3.452605
	2	6.591337
	3	13.433773
	4	20.935342
	5	55.586943
(30, 40]	1	3.538928
	2	7.128413
	3	12.815976
	4	22.143579
	5	54.373104
(40 <b>,</b> 50]	1	3.537576
	2	7.109005
	3	12.677725
	4	22.494922
	5	54.180772
(50 <b>,</b> 60]	1	3.829350
	2	5.988178
	3	10.562837
	4	20.997173
	5	58.622462
(60, 70]	1	3.646087
	2	5.153136
	3	10.500729
	4	19.834711
	5	60.865338



# Rating a wiek



Struktura ocen wewnątrz przedziałów jest zbliżona.

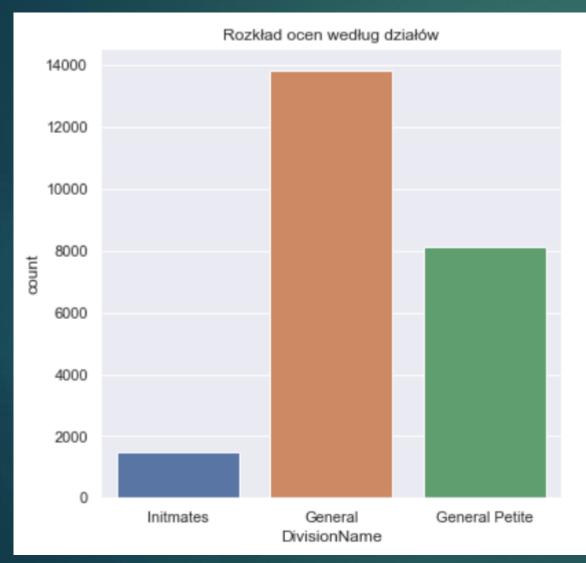
#### Struktura ocen:

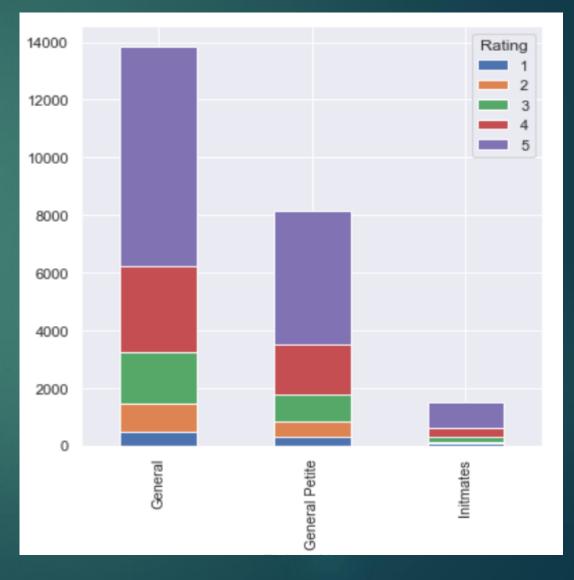
- około 80% to oceny pozytywne
- 10% to oceny neutralne
- 10% to oceny negatywne

#### Rozkład opinii według struktury produktów w sklepie

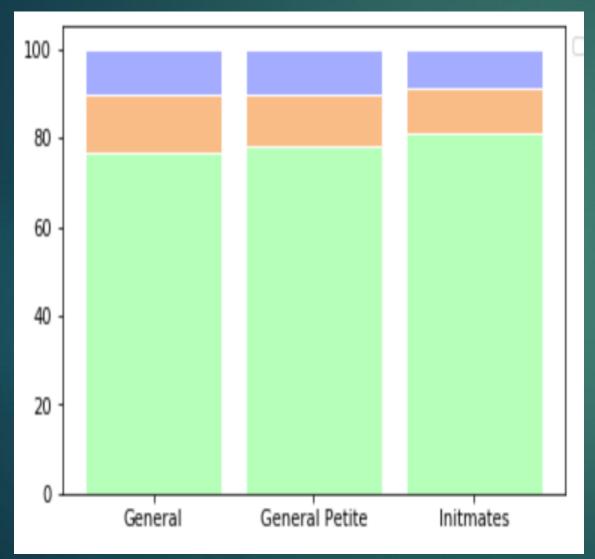
- DZIAŁ
- DEPARTAMENT
- KLASA ODZIEŻY

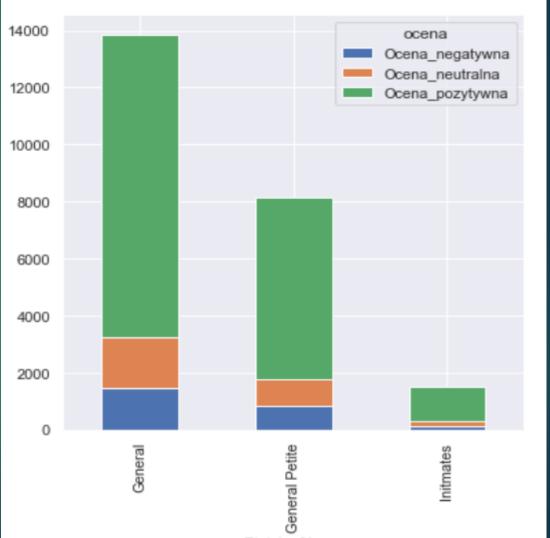
# Rozkład opinii według struktury produktów w sklepie DZIAŁY



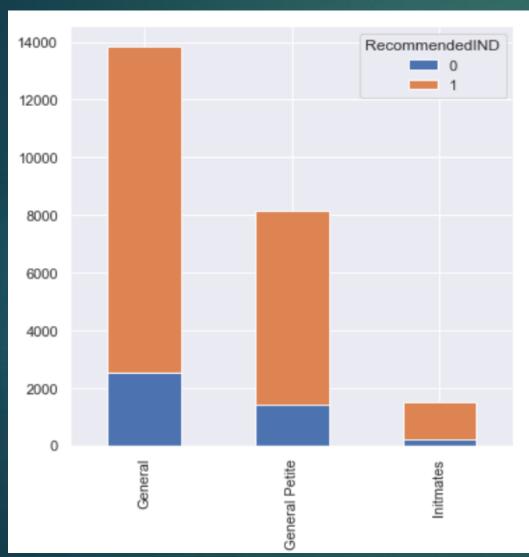


# Rozkład opinii według struktury produktów w sklepie DZIAŁY



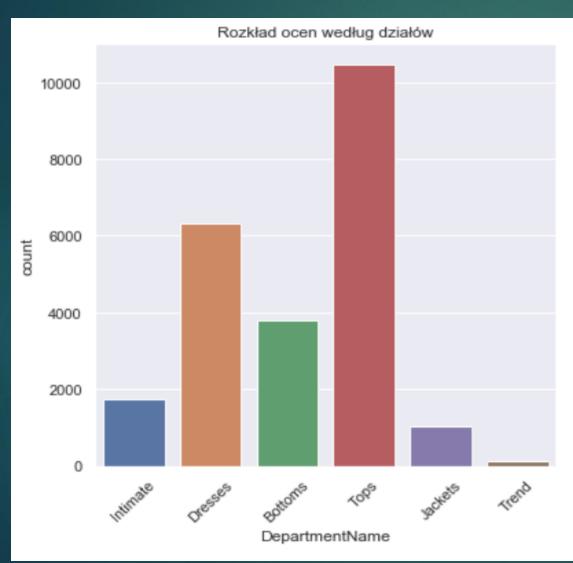


#### Rozkład opinii według struktury produktów w sklepie DZIAŁY



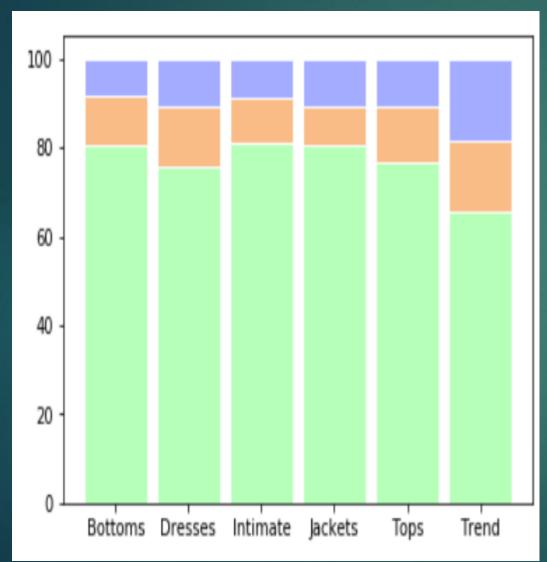
DivisionName	RecommendedIND	
General	0	18.317690
	1	81.682310
General Petite	0	17.401478
	1	82.598522
Initmates	0	14.780293
	1	85.219707

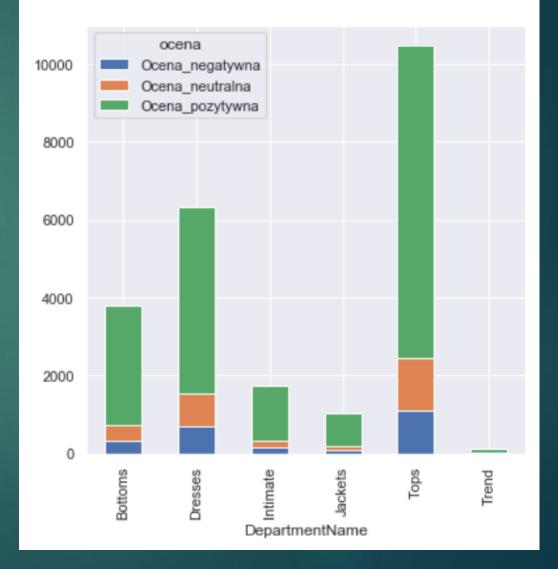
#### Rozkład opinii według struktury produktów w sklepie DEPARTAMENTY



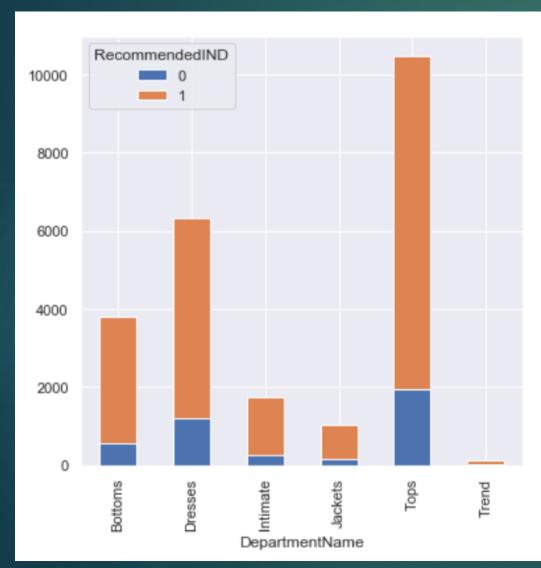
0 1 2 3	DepartmentName Bottoms Dresses Intimate Jackets	Rating 3799 6319 1735 1032	Percentage 16.185242 26.921438 7.391786 4.396728
4	Tops	10468	44.597819
5	Trend	119	0.506987

# Rozkład opinii według struktury produktów w sklepie DEPARTAMENTY



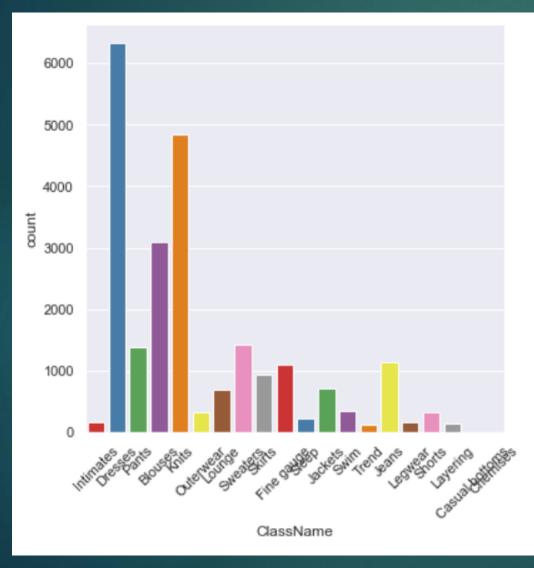


#### Rozkład opinii według struktury produktów w sklepie DEPARTAMENTY



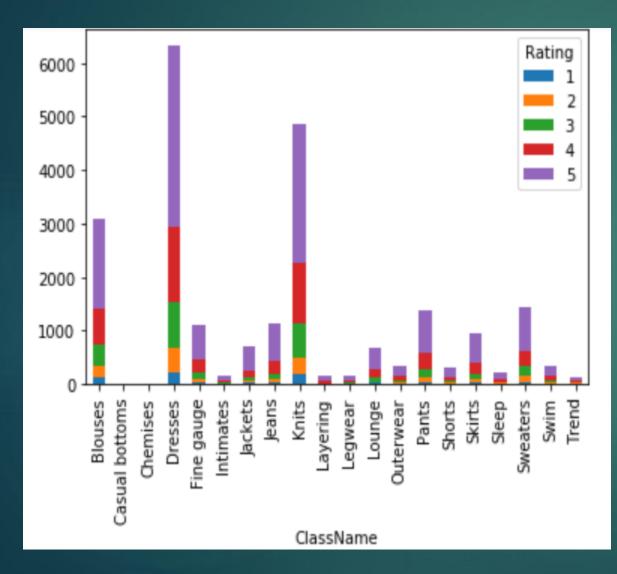
DepartmentName	RecommendedIND	
Bottoms	0	14.872335
	1	85.127665
Dresses	0	19.180250
	1	80.819750
Intimate	0	14.985591
	1	85.014409
Jackets	0	16.375969
	1	83.624031
Tops	0	18.484906
	1	81.515094
Trend	0	26.050420
	1	73.949580

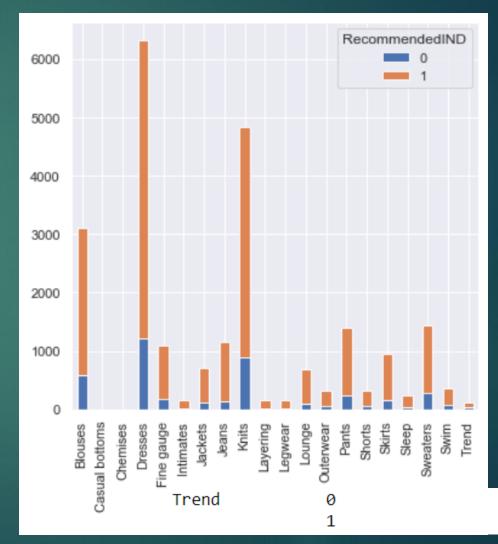
#### Rozkład opinii według struktury produktów w sklepi<mark>e</mark> KLASY UBRAŃ



	ClassName	Rating	Percentage
0	Blouses	3097	13.194444
1	Casual bottoms	2	0.008521
2	Chemises	1	0.004260
3	Dresses	6319	26.921438
4	Fine gauge	1100	4.686435
5	Intimates	154	0.656101
6	Jackets	704	2.999318
7	Jeans	1147	4.886673
8	Knits	4843	20.633095
9	Layering	146	0.622018
10	Legwear	165	0.702965
11	Lounge	691	2.943933
12	Outerwear	328	1.397410
13	Pants	1388	5.913429
14	Shorts	317	1.350545
15	Skirts	945	4.026074
16	Sleep	228	0.971370
17	Sweaters	1428	6.083845
18	Swim	350	1.491138
19	Trend	119	0.506987

#### Rozkład opinii według struktury produktów w sklepie KLASY UBRAŃ

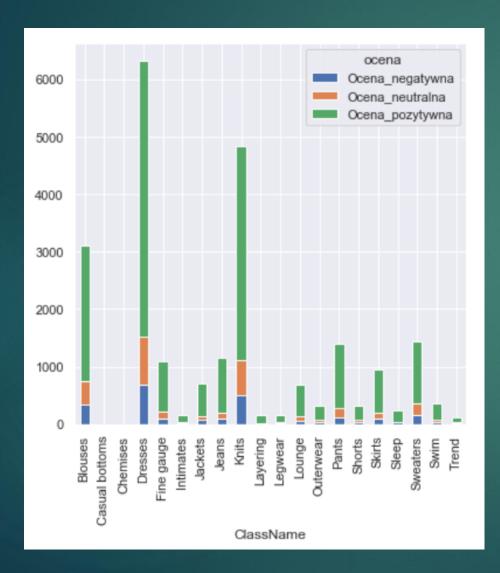


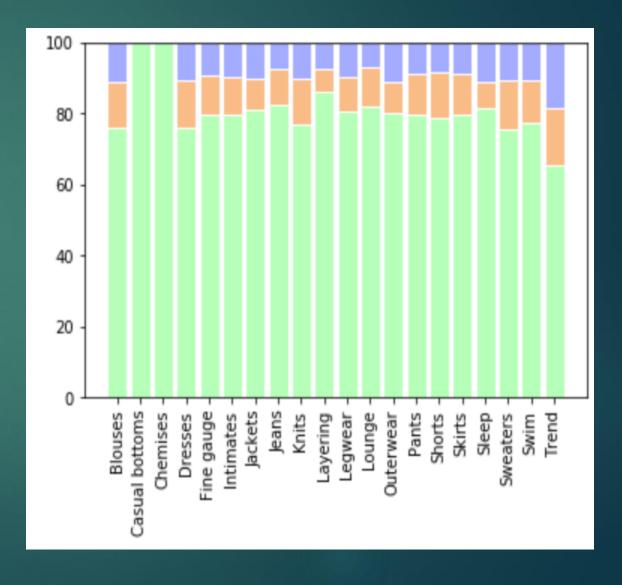


26.050420

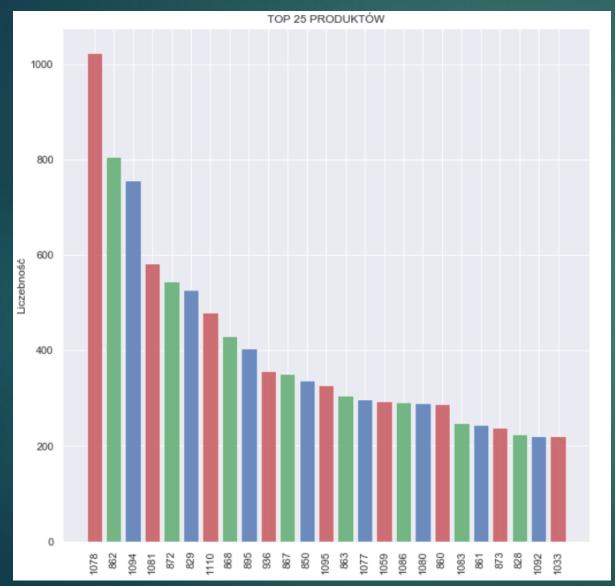
73.949580

#### Rozkład opinii według struktury produktów w sklepie KLASY UBRAŃ





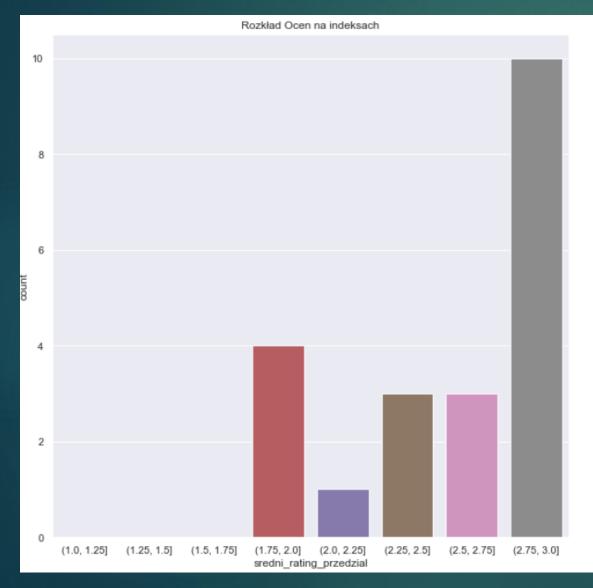
# Clothing ID

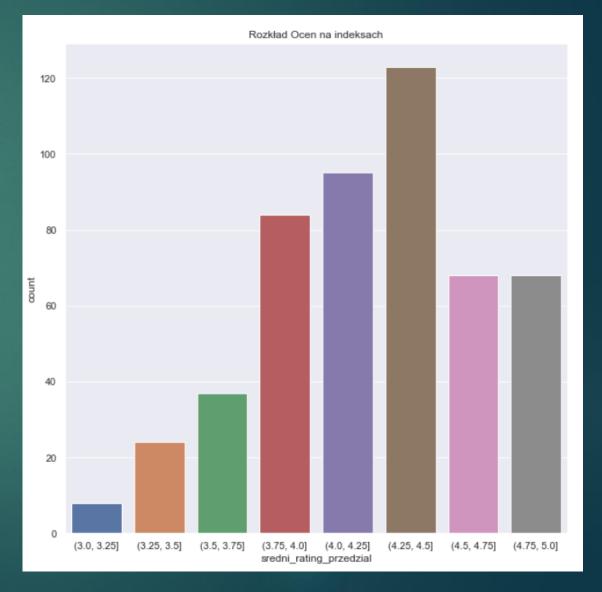


	suma_rating	count	sredni_rating	
count	1206.000000	1206.000000	1206.000000	
mean	81.714760	19.474295	4.198540	
std	291.167303	69.009764	0.849258	
min	1.000000	1.000000	1.000000	
25%	5.000000	1.000000	4.000000	
50%	9.000000	2.000000	4.333333	
75%	26.000000	6.750000	5.000000	
max	4305.000000	1024.000000	5.000000	

25 najczęściej ocenianych detali ma łącznie 10089 ocen czyli 42% wszystkich ocen

# Clothing ID





# Analiza komentarzy

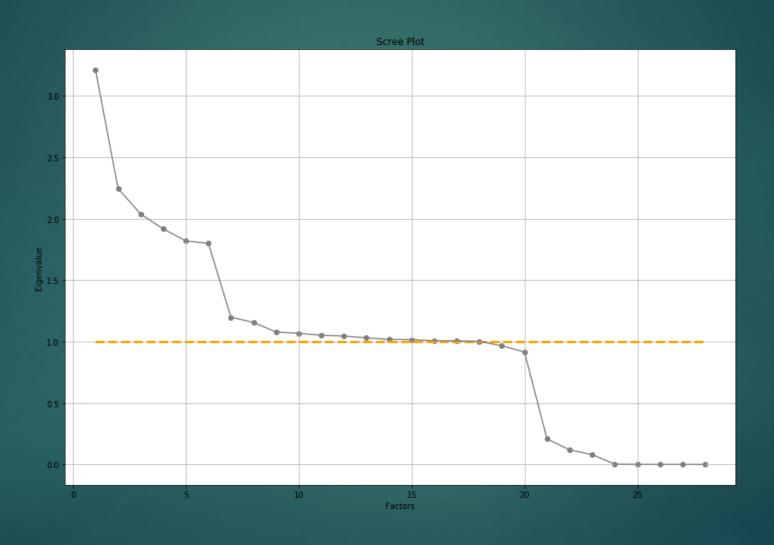
# Analiza czynnikowa

# Przygotowanie danych

- Usunięcie danych z komentarzem oceny
- Stworzenie dummy variables ze zmiennych kategorycznych

- Test Bartlett'a: p-value = 0.0
- KMO Test: 0.12

# Liczba czynników



# Analiza czynników



# Wariancja

	Factor1	Factor2	Factor3	Factor4	Factor5	Factor6
SS Loadings	2.881451	2.002965	1.804096	1.879699	1.597059	1.733448
Proportion Var	0.102909	0.071534	0.064432	0.067132	0.057038	0.061909
Cumulative Var	0.102909	0.174443	0.238875	0.306008	0.363045	0.424954